

## R-тестове

1.  $x = c(267, 91, 103, 39)$   
 $probs = c(0.5, 0.2, 0.2, 0.1)$   
 $chisq.test(x, p=probs)$  - Хи-квадрат тест  
за независимост

2. За проверка на хипотези за пропорция  
може да се използва функцията  $prop.test$ , която  
прави подробен тест

$H_1: p \neq p_0$   $prop.test(x=x, n=n, p=p_0, correct=F)$

$H_1: p > p_0$   $prop.test(x=x, n=n, p=p_0, alternative="greater", correct=F)$

$H_1: p < p_0$   $prop.test(x=x, n=n, p=p_0, alternative="less", correct=F)$

1-sample proportions test ... data: 2700 out of 2500

3. Ако във вектора  $x$  запишем  $x_1, x_2$ , а във вектора  
 $n$  запишем  $n_1, n_2$ , може да използваме функцията

$H_1: p_1 \neq p_2$   $prop.test(x, n, correct=F)$

$H_1: p_1 > p_2$   $prop.test(x, n, alternative="greater", correct=F)$

$H_1: p_1 < p_2$   $prop.test(x, n, alternative="less", correct=F)$

2-sample test for equality ... data: x out of n

4 t-test за средно

- във вектора  $x$  са записани наблюденията  
 $x_1, x_2, \dots, x_n$

$H_1: \mu \neq \mu_0$   $t.test(x, mu=\mu_0)$

$H_1: \mu > \mu_0$   $t.test(x, mu=\mu_0, alternative="greater")$

$H_1: \mu < \mu_0$   $t.test(x, mu=\mu_0, alternative="less")$

$t.test(x, mu=5.2)$ p.value$

// one sample t-test

5 t-test за разлика на средни: Независими извадки

Ако във вектора  $x$  запишем наблюденията  
 $x_1, x_2, \dots, x_n$ , а във вектора  $y$  наблюденията

$y_1, y_2, \dots, y_m$



$$H_1: \mu_x \neq \mu_y \quad t\text{-test}(x, y)$$

$$H_1: \mu_x > \mu_y \quad t\text{-test}(x, y, \text{alternative} = "greater")$$

$$H_1: \mu_x < \mu_y \quad t\text{-test}(x, y, \text{alternative} = "less")$$

// Welch Two Sample t-test

В  $t\text{-test}$  за разлика на средни зависими извадки  
за зависими извадки отново се ползва функцията  
 $t\text{-test}$ , като трябва да се добави  $\text{paired} = T$

(Във вектора  $x$  са наблюдения  $x_1, x_2, \dots, x_n$ , а  
във вектора  $y$  са  $y_1, y_2, \dots, y_n$ ):

$$H_1: \mu_x \neq \mu_y \quad t\text{-test}(x, y, \text{paired} = T)$$

$$H_1: \mu_x > \mu_y \quad t\text{-test}(x, y, \text{alternative} = "greater", \text{paired} = T)$$

$$H_1: \mu_x < \mu_y \quad t\text{-test}(x, y, \text{alternative} = "less", \text{paired} = T)$$

$t\text{-test}(x, y, \text{paired} = T)$  дава отново резултат като  
 $t\text{-test}(x - y)$  // Paired t-test

Г. Линейен модел с един предикатор

Предполагаме, че случайните величини  $Y, X, \varepsilon$  са  
свързани по следния начин:

$$Y = \beta_0 + \beta_1 X + \varepsilon, \quad \beta_0, \beta_1 \text{ са константи}$$

$X$  - предикатор,  $Y$  - отклик

Параметрите  $\beta_0, \beta_1$  са неизвестни и въз основа  
на наблюденията намиране оценките  $\hat{\beta}_0, \hat{\beta}_1$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x \quad \text{- оценено регресионно уравнение, } \hat{y} \text{ - оценка}$$

Проверка на хипотези за  $\beta_1$

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

Ако във вектора  $x$  са наблюденията  $x_1, x_2, \dots, x_n$ ,  
а във вектора  $y$  наблюденията  $y_1, y_2, \dots, y_n$   
 $\text{lm}(y \sim x)$  - оценените модели



## R - подготовка

### 1. Хи-квadrat тест за съгласуваност

Тестовите за съгласуваност (goodness-of-fit tests) се използват, за да се провери доколко данните са съгласувани с даден вероятностен модел (дали този модел описва добре данните)

Разглеждаме експеримент (опит) с ~~к~~ възможни изхода  $A_1, A_2, \dots, A_k$  (пълна група събития). Знаем вероятностите  $P(A_1) = p_1, \dots, P(A_k) = p_k$ . В поредица от  $n$  независими опита  $X_i$  е брой случвания на събитията  $A_i$ . Случайният вектор  $(X_1, X_2, \dots, X_k)$  има полиномно разпределение (multinomial distribution) с параметри  $n, p_1, \dots, p_k$

Искаме да проверим хипотезата

$$H_0: (p_1, p_2, \dots, p_k) = (p_1^0, p_2^0, \dots, p_k^0)$$

$$H_1: (p_1, p_2, \dots, p_k) \neq (p_1^0, p_2^0, \dots, p_k^0), \text{ където}$$

$p_1^0, \dots, p_k^0$  са предварително зададени стойности.

Ако  $p\text{-value} \leq \alpha$ , отхвърляме  $H_0$  в полза на  $H_1$

Ако  $p\text{-value} > \alpha$ , нямаме достатъчно основания да отхвърлим  $H_0$

$$\text{chisq.test}(x, p = probs)$$

8. Линеен модел с няколко предиктора

Предполагаме че случајните величини  $Y, X_1, \dots, X_k$  са свързани по следния начин:

$$Y = \beta_0 + \beta_1 X_1 + \dots + \beta_k X_k + \varepsilon, \beta_0, \beta_1, \dots, \beta_k \text{ са const}$$

$X_1, \dots, X_k$  - предиктори,  $Y$  - отклик  
 $\ln(Y \sim X_1 + X_2)$

9. \* `fn[EAI >= 4]`

\* `sum(spec == "KV" & DAA == 5)`

\* ~~`sum(EAI[spec == "KV"])`~~ \* ~~`length(EAI[spec == "KV"])`~~

\* `mean(EAI[spec == "KV"])` - средно обучение

\* `median(DAA[EAI == 5])`

\* `boxplot(DAA ~ spec)`

`boxplot(table(DAA, spec), beside=T, legend=T)`

10. `sim.dice = function() {`

`x = sample(c(1:6), 4, replace=T)`

`sum(x[1:2]) >= sum(x[3:4])`  
`}`

`sim.prob = function(Nrep) {`

`res = replicate(Nrep, sim.dice())`

`sum(res) / length(res)`  
`}`

`sim.prob(100000)`